TRAVAUX PRATIQUES
MODÈLES LINÉAIRES GÉNÉRALISÉS

Sujet

Prédiction du Décès chez les Patients atteints d'Insuffisance Cardiaque : Application de la Régression Logistique sous R

Préparé par : **Basma HOURMATALLAH**

Filière : Biostatistique, démographie et Big Data

Année universitaire 2025–2026

TABLE DES MATIÈRES

Introduction Générale **3**

1 Description des Données **4**
1.1 Source et présentation du Dataset 4
1.2 Description des variables 5
1.3 Statistiques descriptives 5
1.4 Analyse exploratoire graphique 6
1.4.1 Boxplots des variables continues selon l'issue 6
1.4.2 Matrice de corrélation 7

2 Cadre Théorique : Modèles Linéaires Généralisés **9**
2.1 La famille exponentielle 9
2.2 Structure d'un GLM 9
2.3 La régression logistique 9
2.4 Estimation par maximum de vraisemblance 10
2.5 Interprétation : Odds Ratios 10

3 Méthodologie **11**
3.1 Division des données : split stratifié 80/20 11
3.2 Stratégie de modélisation 12

4 Résultats **14**
4.1 Modèle logistique complet 14
4.2 Sélection du modèle final par Stepwise AIC 15
4.2.1 Odds Ratios du modèle final 16
4.3 Tests d'hypothèses 16
4.3.1 Test du rapport de vraisemblance (LRT) 17
4.3.2 Test de Wald 17
4.3.3 Pseudo-R^2 18
4.4 Adéquation du modèle 18
4.4.1 Test par la déviance résiduelle 18
4.4.2 Test de Hosmer-Lemeshow 19

4.5 Analyse des résidus 19
4.5.1 Graphiques diagnostiques standard 19
4.5.2 Résidus de déviance et de Pearson 20
4.5.3 Points influents – Distance de Cook 21
4.5.4 Leviers et multicolinéarité (VIF) 21
4.6 Comparaison des modèles : Matrices de confusion 22
4.6.1 Sur l'échantillon d'apprentissage (TRAIN) 22
4.6.2 Sur l'échantillon de validation (TEST) 23
4.7 Comparaison des modèles : Courbes ROC 23

5 Discussion et Interprétation **25**
5.1 Interprétation clinique des Odds Ratios 25
5.2 Qualité globale du modèle 26
5.3 Comparaison finale des modèles 26
5.4 Limites 26

Conclusion et Recommandations **27**

A Code R Complet **29**

INTRODUCTION GÉNÉRALE

Les maladies cardiovasculaires représentent aujourd'hui la principale cause de mortalité à l'échelle mondiale, avec près de 18 millions de décès par an selon l'Organisation mondiale de la santé. Parmi ces affections, l'insuffisance cardiaque constitue un enjeu majeur de santé publique en raison de sa forte prévalence, de sa gravité et de son impact économique considérable. Elle se caractérise par une incapacité du cœur à assurer un débit sanguin suffisant pour répondre aux besoins de l'organisme, ce qui entraîne des complications sévères telles que l'insuffisance rénale ou des déséquilibres électrolytiques, souvent associés à une augmentation du risque de mortalité.

Dans ce contexte, la prédiction précoce du risque de décès à partir de données cliniques et biologiques constitue un enjeu essentiel. Elle permettrait d'identifier les patients les plus vulnérables, d'adapter les stratégies thérapeutiques et d'optimiser l'allocation des ressources médicales. Le développement de modèles statistiques performants s'inscrit ainsi pleinement dans la dynamique actuelle de la médecine de précision, visant à améliorer la qualité des soins et la prise de décision clinique.

Sur le plan méthodologique, les modèles linéaires généralisés offrent un cadre théorique particulièrement adapté à l'analyse de variables réponses non continues. La régression logistique, en particulier, constitue l'outil de référence pour modéliser une variable binaire telle que le décès. Elle permet d'estimer la probabilité de survenue de l'événement étudié et d'interpréter l'effet des variables explicatives à travers les Odds Ratios, facilitant ainsi l'analyse clinique des résultats.

Le présent travail s'inscrit dans le cadre du TP de Modèles Linéaires Généralisés et repose sur l'exploitation du Heart Failure Clinical Records Dataset, composé de 299 patients. L'objectif est de construire un modèle de régression logistique permettant de prédire le risque de décès à partir de variables cliniques pertinentes. La démarche adoptée comprend l'exploration des données, la division en échantillons d'apprentissage et de validation, l'ajustement et la sélection du modèle, ainsi que l'évaluation de ses performances prédictives.

CHAPITRE 1

DESCRIPTION DES DONNÉES

1.1 Source et présentation du Dataset

Le jeu de données utilisé est le *Heart Failure Clinical Records Dataset*, rendu public sur Kaggle et issu du dépôt UCI Machine Learning Repository. Il a été collecté dans un hôpital de Faisalabad (Pakistan) entre avril et décembre 2015, sur des patients atteints d'insuffisance cardiaque. Il comporte **299 observations** et **13 variables**, sans aucune valeur manquante ni doublon.

La variable de réponse `DEATH_EVENT` indique si le patient est décédé ($= 1$) ou a survécu ($= 0$) durant la période de suivi.

1.2 Description des variables

TABLE 1.1 – Description des 13 variables du dataset

Variable	Type	Description	Unité
`age`	Continue	Âge du patient	années
`anaemia`	Binaire	Anémie (0=Non, 1=Oui)	–
`creatinine_phosphokinase`	Entier	Taux de CPK dans le sang	mcg/L
`diabetes`	Binaire	Diabète (0=Non, 1=Oui)	–
`ejection_fraction`	Continue	% de sang pompé par contraction	%
`high_blood_pressure`	Binaire	Hypertension artérielle	–
`platelets`	Continue	Plaquettes sanguines	kiloplatelets/mL
`serum_creatinine`	Continue	Créatinine sérique	mg/dL
`serum_sodium`	Continue	Sodium sérique	mEq/L
`sex`	Binaire	Sexe (0=Femme, 1=Homme)	–
`smoking`	Binaire	Tabagisme (0=Non, 1=Oui)	–
`time`	Entier	Durée de suivi médical	jours
`DEATH_EVENT`	**Binaire**	**Décès – variable réponse (0=Survie, 1=Décès)**	–

1.3 Statistiques descriptives

Les statistiques descriptives obtenues avec `summary(df)` sont les suivantes. Le jeu de données est complet : aucune valeur manquante (`colSums(is.na(df))` = 0) et aucun doublon (`sum(duplicated(df))` = 0).

```
> print(summary(df))
      age           anaemia       creatinine_phosphokinase    diabetes       ejection_fraction
 Min.   :40.00   Min.   :0.0000   Min.   :  23.0           Min.   :0.0000   Min.   :14.00
 1st Qu.:51.00   1st Qu.:0.0000   1st Qu.: 116.5           1st Qu.:0.0000   1st Qu.:30.00
 Median :60.00   Median :0.0000   Median : 250.0           Median :0.0000   Median :38.00
 Mean   :60.83   Mean   :0.4314   Mean   : 581.8           Mean   :0.4181   Mean   :38.08
 3rd Qu.:70.00   3rd Qu.:1.0000   3rd Qu.: 582.0           3rd Qu.:1.0000   3rd Qu.:45.00
 Max.   :95.00   Max.   :1.0000   Max.   :7861.0           Max.   :1.0000   Max.   :80.00
 high_blood_pressure   platelets       serum_creatinine  serum_sodium        sex
 Min.   :0.0000      Min.   : 25100   Min.   :0.500    Min.   :113.0   Min.   :0.0000
 1st Qu.:0.0000      1st Qu.:212500   1st Qu.:0.900    1st Qu.:134.0   1st Qu.:0.0000
 Median :0.0000      Median :262000   Median :1.100    Median :137.0   Median :1.0000
 Mean   :0.3512      Mean   :263358   Mean   :1.394    Mean   :136.6   Mean   :0.6488
 3rd Qu.:1.0000      3rd Qu.:303500   3rd Qu.:1.400    3rd Qu.:140.0   3rd Qu.:1.0000
 Max.   :1.0000      Max.   :850000   Max.   :9.400    Max.   :148.0   Max.   :1.0000
    smoking            time        DEATH_EVENT
 Min.   :0.0000   Min.   :  4.0   Min.   :0.0000
 1st Qu.:0.0000   1st Qu.: 73.0   1st Qu.:0.0000
 Median :0.0000   Median :115.0   Median :0.0000
 Mean   :0.3211   Mean   :130.3   Mean   :0.3211
 3rd Qu.:1.0000   3rd Qu.:203.0   3rd Qu.:1.0000
 Max.   :1.0000   Max.   :285.0   Max.   :1.0000
```

Les statistiques descriptives montrent que l'âge moyen des patients est d'environ 60,8 ans, avec une médiane de 60 ans et des valeurs comprises entre 40 et 95 ans, ce qui indique une population relativement âgée. La fraction d'éjection, indicateur clé de la fonction cardiaque, présente une moyenne de 38%, traduisant globalement une fonction cardiaque altérée chez les patients étudiés. La créatinine sérique a une moyenne de 1,39 mg/dL, avec des valeurs pouvant atteindre 9,4, ce qui suggère la présence de cas sévères de dysfonction rénale.

Les variables biologiques montrent une certaine dispersion, notamment pour la créatine phosphokinase (CPK), dont la moyenne est élevée (581,8) avec un maximum très important (7861), indiquant la présence de valeurs extrêmes. En revanche, le sodium sérique est relativement stable autour d'une moyenne de 136,6 mEq/L. Le nombre de plaquettes présente également une forte variabilité, avec des valeurs allant de 25 100 à 850 000.

Concernant les variables qualitatives, environ 43% des patients souffrent d'anémie, 41,8% sont diabétiques et 35,1% présentent une hypertension artérielle. La majorité des patients sont des hommes (environ 65%) et 32% sont fumeurs. Enfin, la variable réponse indique qu'environ 32% des patients sont décédés, ce qui met en évidence un déséquilibre modéré entre les classes. La durée moyenne de suivi est de 130 jours, avec une dispersion importante, reflétant une hétérogénéité dans la prise en charge et l'évolution des patients.

1.4 Analyse exploratoire graphique

1.4.1 Boxplots des variables continues selon l'issue

La figure 1.1 présente les boîtes à moustaches de chaque variable continue selon la variable réponse (Survie vs Décès). On observe notamment que :

- Les patients décédés sont en moyenne **plus âgés** que les survivants.
- La **fraction d'éjection** est nettement **plus faible** chez les patients décédés, confirmant son rôle de marqueur pronostique majeur.
- La **créatinine sérique** est significativement **plus élevée** en cas de décès, traduisant une dysfonction rénale associée.
- Le **sodium sérique** est plus bas chez les patients décédés (hyponatrémie pronostique défavorable).
- La **durée de suivi** est très nettement plus courte dans le groupe des décédés, reflétant un pronostic plus sombre.
- Le CPK et les plaquettes ne montrent pas de différence visible entre les deux groupes.

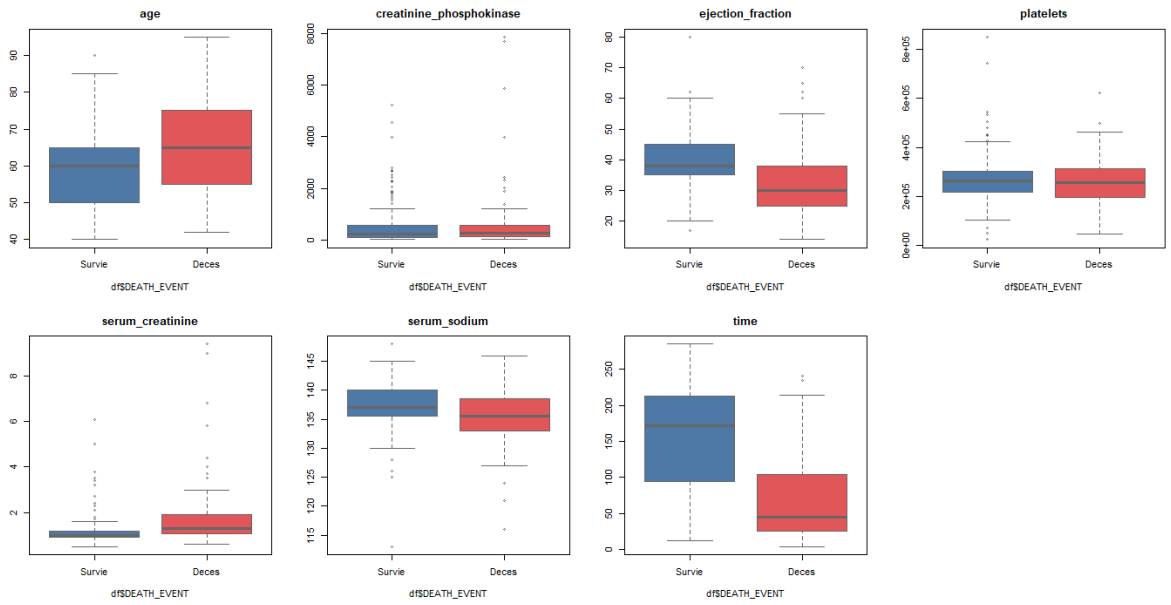

FIGURE 1.1 – Boxplots des variables continues selon l'issue (Survie vs Décès)

1.4.2 Matrice de corrélation

La figure 1.2 présente la matrice de corrélation des variables continues. Les corrélations observées sont toutes faibles (valeur absolue $< 0{,}25$), ce qui **n'indique pas de problème de multicolinéarité** a priori entre les prédicteurs. On note notamment :

— Une corrélation négative faible entre `age` et `time` ($r = -0{,}22$), attendue cliniquement.

— Une corrélation positive faible entre `serum_creatinine` et `age` ($r = 0{,}16$).

— Une absence quasi-totale de corrélation entre CPK et les autres variables.

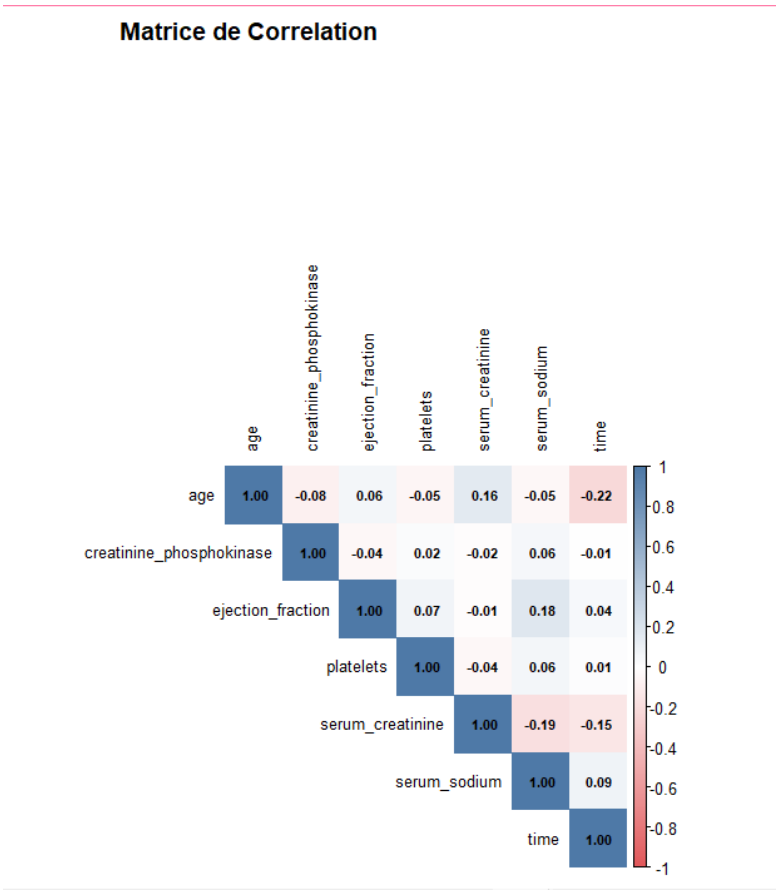

FIGURE 1.2 – Matrice de corrélation des variables continues

CHAPITRE 2

CADRE THÉORIQUE : MODÈLES LINÉAIRES GÉNÉRALISÉS

2.1 La famille exponentielle

Un GLM suppose que la distribution de la variable réponse Y appartient à la **famille exponentielle**, dont la forme générale est :

$$f(y;\,\theta,\phi) = \exp\left\{\frac{y\,\theta - b(\theta)}{a(\phi)} + c(y,\phi)\right\}$$

où θ est le paramètre naturel canonique, ϕ le paramètre de dispersion, et $b(\cdot)$, $a(\cdot)$, $c(\cdot)$ des fonctions connues. On montre que :

$$\mathbb{E}[Y] = b'(\theta) \qquad \text{et} \qquad \mathrm{Var}(Y) = a(\phi)\,b''(\theta)$$

Dans notre cas, `DEATH_EVENT` $\sim \mathcal{B}(1,\pi)$ (loi de Bernoulli), avec paramètre naturel $\theta = \ln\left(\frac{\pi}{1-\pi}\right)$ et $b(\theta) = \ln(1+e^{\theta})$.

2.2 Structure d'un GLM

Tout GLM est défini par trois composantes :

1. **Composante aléatoire :** $Y_i \sim$ loi de la famille exponentielle de moyenne μ_i.
2. **Composante systématique :** $\eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$.
3. **Fonction de lien :** $g(\mu_i) = \eta_i$.

2.3 La régression logistique

Pour une variable réponse binaire, le **lien logit** (lien canonique de Bernoulli) modélise :

$$g(\pi_i) = \mathrm{logit}(\pi_i) = \ln\left(\frac{\pi_i}{1-\pi_i}\right) = \beta_0 + \sum_{j=1}^{p} \beta_j\, x_{ij}$$

d'où la probabilité ajustée :

$$\hat{\pi}_i = \frac{\exp(\hat{\eta}_i)}{1 + \exp(\hat{\eta}_i)} \in (0, 1)$$

2.4 Estimation par maximum de vraisemblance

Les paramètres $\boldsymbol{\beta}$ sont estimés par maximisation de la log-vraisemblance :

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \big[y_i \ln(\hat{\pi}_i) + (1 - y_i) \ln(1 - \hat{\pi}_i) \big]$$

La résolution passe par l'algorithme **IRLS** (*Iteratively Reweighted Least Squares*), implémenté dans `glm()` sous R.

2.5 Interprétation : Odds Ratios

$$OR_j = e^{\hat{\beta}_j}$$

— $OR_j > 1$: X_j augmente le risque de décès.

— $OR_j < 1$: X_j est un facteur protecteur.

— $OR_j = 1$: X_j n'a pas d'effet.

CHAPITRE 3

MÉTHODOLOGIE

3.1 Division des données : split stratifié 80/20

Dans le cadre de ce travail, les données ont été divisées en deux sous-échantillons distincts selon une approche d'échantillonnage stratifié, afin de garantir une représentation équilibrée de la variable réponse `DEATH_EVENT` dans chaque sous-ensemble.

Cette division a été réalisée à l'aide de la fonction createDataPartition() du package caret sous R, en fixant la graine aléatoire avec set.seed(42) pour assurer la reproductibilité des résultats.

Ainsi, 80% des observations, ont été affectées à l'échantillon d'apprentissage (TRAIN), utilisé pour l'estimation des modèles, tandis que les 20% restants, constituent l'échantillon de validation (TEST), destiné à évaluer les performances prédictives du modèle sur des données non utilisées lors de l'ajustement.

```
=== DISTRIBUTION DE DEATH_EVENT ===
> tab_rep <- table(df$DEATH_EVENT)
> print(tab_rep)

  0   1
203  96
> print(round(prop.table(tab_rep) * 100, 1))

   0    1
67.9 32.1


=== TAILLES DES ECHANTILLONS ===
> cat("Train :", nrow(train), "observations\n")
Train : 240 observations
> cat("Test  :", nrow(test),  "observations\n")
Test  : 59 observations
> cat("\n=== REPARTITION DE DEATH_EVENT DANS LE TRAIN ===\n")

=== REPARTITION DE DEATH_EVENT DANS LE TRAIN ===
> print(round(prop.table(table(train$DEATH_EVENT)) * 100, 1))

   0    1
67.9 32.1
> cat("\n=== REPARTITION DE DEATH_EVENT DANS LE TEST ===\n")

=== REPARTITION DE DEATH_EVENT DANS LE TEST ===
> print(round(prop.table(table(test$DEATH_EVENT)) * 100, 1))

   0    1
67.8 32.2
```

FIGURE 3.1 – Répartition après le split stratifié 80/20

La stratification garantit que la proportion de décès ($\approx 32\%$) est identique dans les deux échantillons, évitant tout biais de sélection.

3.2 Stratégie de modélisation

La démarche de modélisation adoptée repose sur une approche progressive visant à identifier un modèle à la fois performant et interprétable. Dans un premier temps, un modèle nul, ne contenant aucune variable explicative, est estimé afin de servir de référence. Ensuite, un modèle complet intégrant l'ensemble des variables explicatives disponibles est ajusté sur l'échantillon d'apprentissage.

Afin d'obtenir un modèle plus parcimonieux, une procédure de sélection automatique des variables est mise en œuvre en utilisant l'algorithme stepwise bidirectionnel basé sur le critère (AIC). Cette méthode permet de retenir uniquement les variables contribuant significativement à l'explication de la variable réponse, tout en évitant le surajustement.

Une fois le modèle final sélectionné, plusieurs tests statistiques sont réalisés pour

évaluer sa pertinence. Le test du rapport de vraisemblance permet de comparer les modèles emboîtés, tandis que le test de Wald permet de vérifier la significativité individuelle des coefficients estimés. Des indicateurs globaux, tels que les pseudo-coefficients de détermination, sont également utilisés pour apprécier la qualité d'ajustement du modèle.

L'adéquation du modèle aux données est ensuite examinée à l'aide de la déviance résiduelle ainsi que du test de Hosmer-Lemeshow, qui permet d'évaluer la qualité de la calibration. Par ailleurs, une analyse approfondie des résidus est menée afin de détecter d'éventuelles observations atypiques ou influentes, à travers l'étude des résidus de déviance, des résidus de Pearson, de la distance de Cook et des leviers. La présence éventuelle de multicolinéarité entre les variables explicatives est également vérifiée à l'aide du facteur d'inflation de la variance (VIF).

Enfin, les performances prédictives du modèle sont évaluées sur l'échantillon de validation à l'aide de matrices de confusion, permettant de calculer des indicateurs tels que l'accuracy, la sensibilité et la spécificité. Les courbes ROC et l'aire sous la courbe (AUC) sont également utilisées afin d'évaluer le pouvoir discriminant du modèle et de comparer les différentes spécifications considérées. Cette démarche complète permet d'assurer à la fois la robustesse statistique du modèle et sa pertinence dans un contexte applicatif réel.

CHAPITRE 4

RÉSULTATS

4.1 Modèle logistique complet

Le modèle complet ajusté sur le TRAIN ($n = 240$) avec les 12 variables explicatives donne les résultats suivants :

```
Coefficients:
                          Estimate Std. Error z value Pr(>|z|)
(Intercept)              1.578e+01  6.943e+00   2.273   0.0230 *
age                      4.134e-02  1.797e-02   2.300   0.0214 *
anaemia1                -8.507e-02  4.309e-01  -0.197   0.8435
creatinine_phosphokinase -6.997e-06  1.915e-04  -0.037   0.9709
diabetes1               -5.772e-02  4.141e-01  -0.139   0.8891
ejection_fraction       -9.075e-02  2.056e-02  -4.414 1.01e-05 ***
high_blood_pressure1     1.602e-01  4.217e-01   0.380   0.7040
platelets               -8.563e-07  2.325e-06  -0.368   0.7126
serum_creatinine         7.836e-01  1.997e-01   3.924 8.69e-05 ***
serum_sodium            -1.035e-01  4.812e-02  -2.150   0.0315 *
sex1                     3.438e-02  4.896e-01   0.070   0.9440
smoking1                -1.399e-01  4.736e-01  -0.295   0.7677
time                    -2.347e-02  3.707e-03  -6.330 2.45e-10 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)
```

```
Deviance nulle     : 301.198
> cat("Deviance residuelle:", round(deviance(model_complet), 3), "\n")
Deviance residuelle: 161.062
> cat("AIC                :", round(AIC(model_complet), 2), "\n")
AIC                : 187.06
> cat("BIC                :", round(BIC(model_complet), 2), "\n")
BIC                : 232.31
> cat("\n=== ODDS RATIOS MODELE COMPLET (IC 95%) ===\n")
```

Les résultats du modèle logistique complet montrent que certaines variables jouent un rôle significatif dans la prédiction du décès. En particulier, l'âge a un effet positif et significatif, indiquant que le risque de décès augmente avec l'âge. À l'inverse, la fraction d'éjection a un effet négatif très significatif, ce qui signifie qu'une meilleure fonction cardiaque réduit fortement le risque de décès. La créatinine sérique apparaît également comme un facteur de risque majeur, avec un effet positif significatif, traduisant l'impact

important de la fonction rénale sur le pronostic. Le sodium sérique présente un effet négatif significatif, suggérant qu'un taux plus élevé est associé à une diminution du risque de décès. Enfin, la variable time est fortement significative et négative, indiquant que plus la durée de suivi est longue, plus le risque de décès diminue.

En revanche, plusieurs variables comme l'anémie, le diabète, l'hypertension, les plaquettes, le sexe, le tabagisme ou encore la créatine phosphokinase ne sont pas significatives, ce qui suggère qu'elles n'apportent pas d'information supplémentaire dans la présence des autres variables du modèle.

Par ailleurs, la qualité globale du modèle est satisfaisante. La déviance résiduelle (161,06) est nettement inférieure à la déviance nulle (301,20), ce qui indique une amélioration importante de l'ajustement grâce aux variables explicatives. L'AIC de 187,06 et le BIC de 232,31 confirment également la pertinence du modèle, tout en laissant envisager une simplification possible.

4.2 Sélection du modèle final par Stepwise AIC

La procédure *stepwise* bidirectionnelle aboutit à la **rétention de 5 variables** : `age`, `ejection_fraction`, `serum_creatinine`, `serum_sodium` et `time`.

```
Coefficients:
                  Estimate Std. Error z value Pr(>|z|)
(Intercept)       15.48086    6.73894   2.297   0.0216 *
age                0.04247    0.01758   2.416   0.0157 *
ejection_fraction -0.09095    0.02024  -4.494 6.98e-06 ***
serum_creatinine   0.79533    0.19641   4.049 5.14e-05 ***
serum_sodium      -0.10377    0.04733  -2.192   0.0284 *
time              -0.02336    0.00357  -6.543 6.05e-11 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 301.20  on 239  degrees of freedom
Residual deviance: 161.53  on 234  degrees of freedom
AIC: 173.53

Number of Fisher Scoring iterations: 6
```

Les résultats confirment que l'âge et la créatinine sérique augmentent le risque de décès, tandis que la fraction d'éjection, le sodium sérique et la durée de suivi ont un effet protecteur. Ce modèle, plus simple que le modèle complet, conserve une forte capacité explicative tout en étant plus facilement interprétable sur le plan clinique.

4.2.1 Odds Ratios du modèle final

```
=== ODDS RATIOS MODELE FINAL (IC 95%) ===
> OR_final <- exp(cbind(OR     = coef(model_final),
+                       IC_inf = confint.default(model_final)[, 1],
+                       IC_sup = confint.default(model_final)[, 2]))
> print(round(OR_final, 4))
                            OR IC_inf       IC_sup
(Intercept)       5287530.8189 9.7064 2.880368e+12
age                     1.0434 1.0081 1.080000e+00
ejection_fraction       0.9131 0.8776 9.500000e-01
serum_creatinine        2.2152 1.5074 3.255300e+00
serum_sodium            0.9014 0.8216 9.891000e-01
time                    0.9769 0.9701 9.838000e-01
> cat("\n=== TEST LRT : modele final vs modele nul ===\n")
```

FIGURE 4.3 – Odds Ratios et IC à 95% – Modèle final

Les Odds Ratios du modèle final confirment l'importance des variables retenues. L'âge augmente légèrement le risque de décès, avec une hausse d'environ 4,3% par année supplémentaire. À l'inverse, la fraction d'éjection et le sodium sérique ont un effet protecteur, une augmentation de ces variables étant associée à une diminution du risque. La créatinine sérique apparaît comme le facteur de risque le plus important, multipliant le risque de décès par plus de 2 pour chaque unité supplémentaire. Enfin, la durée de suivi a également un effet protecteur significatif, indiquant qu'un suivi plus long est associé à une réduction du risque de décès.

4.3 Tests d'hypothèses

4.3.1 Test du rapport de vraisemblance (LRT)

```
=== TEST LRT : modele final vs modele nul ===
> print(lrtest(model_nul, model_final))
Likelihood ratio test

Model 1: DEATH_EVENT_num ~ 1
Model 2: DEATH_EVENT_num ~ age + ejection_fraction + serum_creatinine +
    serum_sodium + time
  #Df   LogLik Df  Chisq Pr(>Chisq)
1   1 -150.599
2   6  -80.764  5 139.67  < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
> cat("\n=== TEST LRT : modele complet vs modele final ===\n")

=== TEST LRT : modele complet vs modele final ===
> print(lrtest(model_final, model_complet))
Likelihood ratio test

Model 1: DEATH_EVENT_num ~ age + ejection_fraction + serum_creatinine +
    serum_sodium + time
Model 2: DEATH_EVENT_num ~ age + anaemia + creatinine_phosphokinase +
    diabetes + ejection_fraction + high_blood_pressure + platelets +
    serum_creatinine + serum_sodium + sex + smoking + time
  #Df  LogLik Df Chisq Pr(>Chisq)
1   6 -80.764
2  13 -80.531  7 0.466     0.9996
> cat("\n=== TEST DE WALD (z-values) ===\n")
```

Le test du rapport de vraisemblance montre que le modèle final est globalement très significatif par rapport au modèle nul, avec une statistique de Chi-deux élevée (139,67) et une p-valeur très faible (p < 2,2e-16). Cela signifie que les variables explicatives retenues apportent une information essentielle pour expliquer le risque de décès.

LRT modèle complet vs modèle final : $\chi^2(7) = 0{,}466$, $p = 0{,}9996$: les 7 variables retirées par le *stepwise* n'apportent aucune amélioration significative, , ce qui confirme que le modèle final, plus simple, est suffisant et préférable.

4.3.2 Test de Wald

```
=== TEST DE WALD (z-values) ===
> print(round(coef(summary(model_final)), 4))
                  Estimate Std. Error z value Pr(>|z|)
(Intercept)        15.4809     6.7389  2.2972   0.0216
age                 0.0425     0.0176  2.4163   0.0157
ejection_fraction  -0.0909     0.0202 -4.4943   0.0000
serum_creatinine    0.7953     0.1964  4.0493   0.0001
serum_sodium       -0.1038     0.0473 -2.1924   0.0284
time               -0.0234     0.0036 -6.5426   0.0000
```

Le test de Wald confirme que toutes les variables du modèle final sont statistiquement significatives au seuil de 5%. L'âge et la créatinine sérique ont un effet positif sur le risque de décès, tandis que la fraction d'éjection, le sodium sérique et la durée de suivi présentent

un effet négatif, donc protecteur. Les valeurs élevées des statistiques z, notamment pour la durée de suivi et la fraction d'éjection, indiquent une forte contribution de ces variables dans l'explication du phénomène étudié.

4.3.3 Pseudo-R^2

```
=== PSEUDO R2 ===
> cat("McFadden  :", round(r2_mcf, 4), "\n")
McFadden  : 0.4637
> cat("Cox-Snell :", round(r2_cox, 4), "\n")
Cox-Snell : 0.4412
> cat("Nagelkerke:", round(r2_nag, 4), "\n")
Nagelkerke: 0.6171
```

FIGURE 4.6 – Pseudo-R2 du modèle final

Un McFadden > 0,4 est qualifié d'**excellent** ajustement dans la littérature. Le Nagelkerke de 0,617 signifie que le modèle explique environ 61,7% de la variabilité de `DEATH_EVENT`.

4.4 Adéquation du modèle

4.4.1 Test par la déviance résiduelle

$$D_{\text{résid}} = 161{,}53, \quad \text{ddl} = 234, \quad p = 1 - F_{\chi^2_{234}}(161{,}53) = 0{,}9999$$

```
=== TEST D'ADEQUATION PAR LA DEVIANCE ===
> cat("Deviance residuelle :", round(dev_res, 4), "\n")
Deviance residuelle : 161.528
> cat("Degres de liberte   :", ddl, "\n")
Degres de liberte   : 234
> cat("p-value (chi2)      :", round(p_dev, 4), "\n")
p-value (chi2)      : 0.9999
> if (p_dev > 0.05) cat("=> Bonne adequation du modele (p > 0.05)\n") else
+   cat("=> Manque d adequation (p < 0.05)\n")
=> Bonne adequation du modele (p > 0.05)
```

Le test d'adéquation par la déviance montre que la déviance résiduelle du modèle est de 161,53 pour 234 degrés de liberté. La p-value associée est très élevée (0,9999), largement supérieure au seuil de 5%, ce qui indique qu'il n'existe pas de différence significative entre les valeurs observées et celles prédites par le modèle. Ainsi, le modèle présente une bonne adéquation aux données et semble correctement spécifié.

4.4.2 Test de Hosmer-Lemeshow

$$\hat{C} = \sum_{j=1}^{10} \left[\frac{(O_{1j} - E_{1j})^2}{E_{1j}} + \frac{(O_{0j} - E_{0j})^2}{E_{0j}} \right] = 6{,}079, \quad \text{ddl} = 8, \quad p = 0{,}638$$

```
=== TEST DE HOSMER-LEMESHOW ===
Statistique X2     : 6.0789
Degres de liberte : 8
p-value            : 0.6384
=> Bonne adequation (p > 0.05)
```

$p = 0{,}638 > 0{,}05$: **bonne calibration** du modèle. Il n'existe pas de différence significative entre les fréquences observées et les probabilités prédites par le modèle.

4.5 Analyse des résidus

4.5.1 Graphiques diagnostiques standard

La figure 4.14 présente les quatre graphiques diagnostiques standard produits par `plot(model_final)` :

— **Residuals vs Fitted :** les résidus sont globalement centrés autour de zéro sans structure particulière. Les observations 247, 21 et 132 se distinguent par des résidus élevés.

— **Q-Q Residuals :** la distribution des résidus standardisés s'écarte légèrement de la diagonale dans les queues, comportement attendu pour un modèle logistique avec variable binaire.

— **Scale-Location :** la dispersion des résidus est relativement homogène sur l'étendue des valeurs ajustées.

— **Residuals vs Leverage :** l'observation 132 présente un levier élevé ($h \approx 0{,}5$) et un résidu important, la positionnant dans la zone de forte influence.

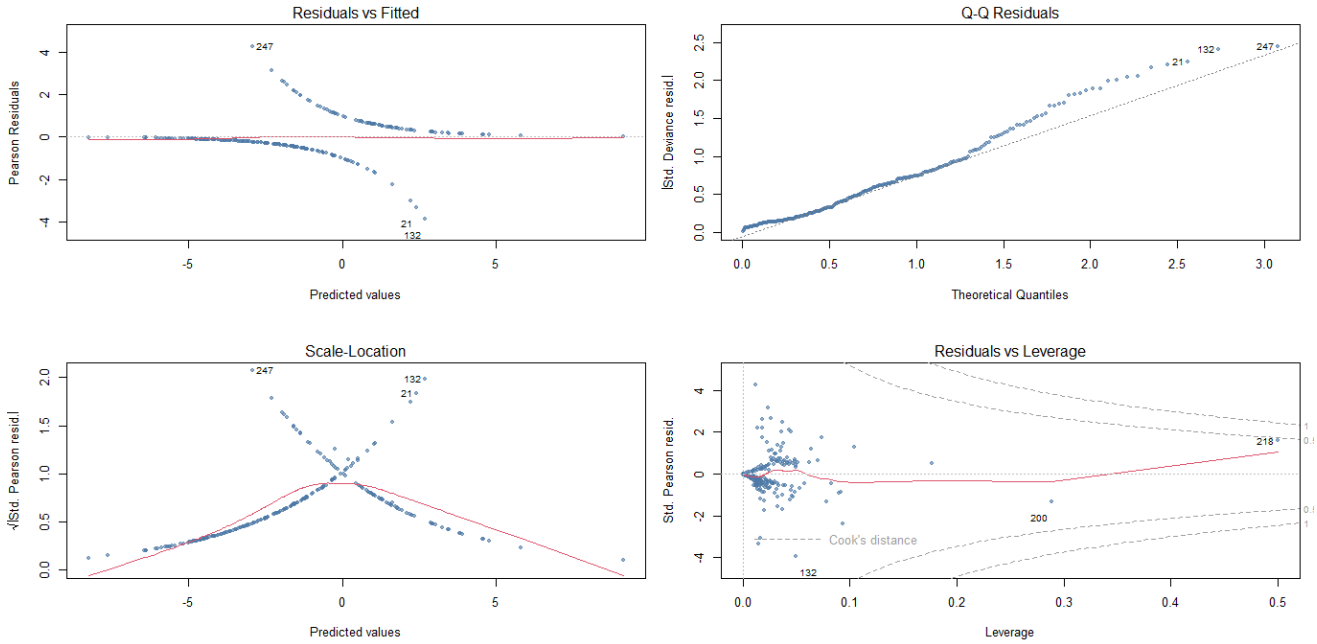

FIGURE 4.9 – Graphiques diagnostiques standard du modèle logistique final

4.5.2 Résidus de déviance et de Pearson

Les résidus de déviance sont définis par :

$$d_i = \text{sign}(y_i - \hat{\pi}_i) \cdot \sqrt{2\left[y_i \ln\frac{y_i}{\hat{\pi}_i} + (1-y_i)\ln\frac{1-y_i}{1-\hat{\pi}_i}\right]}$$

```
=== RESIDUS DE DEVIANCE ===
> print(round(summary(res_dev), 4))
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-2.3496 -0.5364 -0.1613 -0.0585  0.4305  2.4308
```

Les statistiques des résidus de déviance sont : Min $= -2{,}350$; Q1 $= -0{,}536$; Médiane $= -0{,}161$; Moyenne $= -0{,}059$; Q3 $= 0{,}431$; Max $= 2{,}431$.

La figure 4.10a représente les résidus sans annotation, et la figure 4.10b identifie les 7 observations avec $|d_i| > 2$ (seuil standard) : observations **19, 35, 91, 103, 130, 168 et 197**. Ces points correspondent à des patients mal prédits par le modèle mais ne représentent que **2,9%** de l'échantillon d'apprentissage.

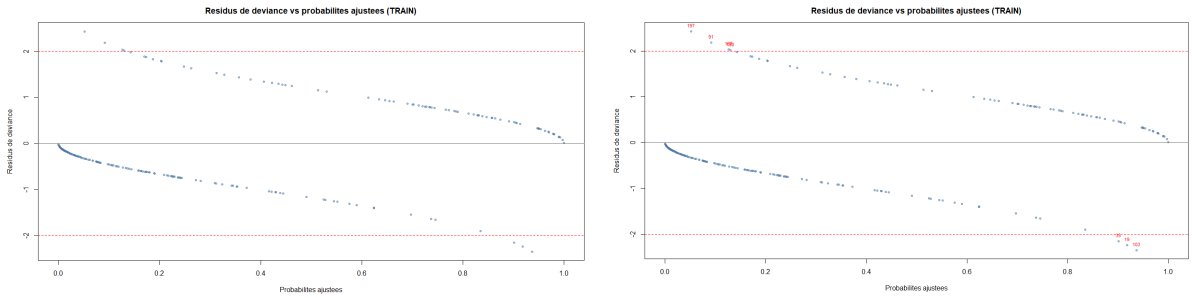

(a) Sans annotation (b) Avec identification des points aberrants

FIGURE 4.10 – Résidus de déviance vs probabilités ajustées – Échantillon TRAIN

Les résidus de Pearson présentent des valeurs extrêmes légèrement plus marquées (Min = −3,85 ; Max = 4,27), caractéristique attendue pour un modèle logistique avec des probabilités proches de 0 ou 1.

4.5.3 Points influents – Distance de Cook

La figure 4.11 représente la distance de Cook pour chaque observation de l'échantillon d'apprentissage. En appliquant le seuil $4/n = 4/240 \approx 0{,}0167$, **18 observations** sont identifiées comme potentiellement influentes : 7, 8, 14, 19, 35, 52, 84, 91, 103, 130, 153, 157, 168, 171, 180, 182, 197 et 211. L'observation la plus influente dépasse $D_i = 0{,}40$.

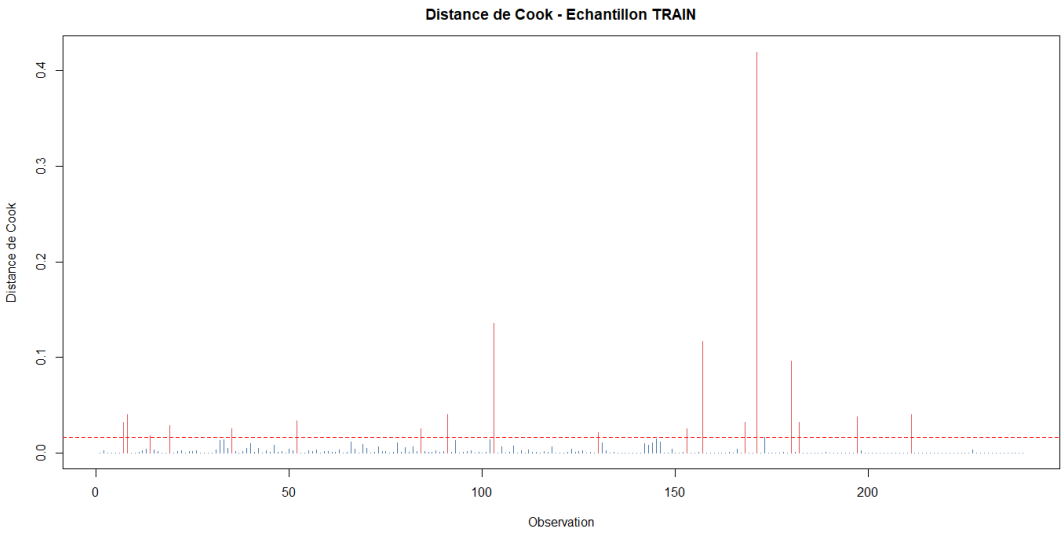

FIGURE 4.11 – Distance de Cook – Échantillon TRAIN (seuil $4/n = 0{,}0167$ en tirets rouges)

4.5.4 Leviers et multicolinéarité (VIF)

Leviers : avec le seuil $2p/n = 2 \times 6/240 = 0{,}05$, on identifie **16 points à levier élevé**. Aucun n'est suffisamment éloigné pour invalider le modèle.

VIF : Le facteur d'inflation de la variance confirme l'**absence totale de multicolinéarité** entre les prédicteurs du modèle final :

```
=== VIF (Variance Inflation Factor) ===
> print(round(vif(model_final), 3))
              age ejection_fraction  serum_creatinine      serum_sodium              time
            1.061            1.245             1.184             1.089             1.211
> cat("=> VIF < 5 : pas de multicollinearite\n")
=> VIF < 5 : pas de multicollinearite
```

FIGURE 4.12 – VIF du modèle final– Absence de multicolinéarité

4.6 Comparaison des modèles : Matrices de confusion

4.6.1 Sur l'échantillon d'apprentissage (TRAIN)

```
--- Matrice de confusion : TRAIN - Modele final (seuil = 0.5 )---
                 Predit 0   Predit 1
  Observe 0        148         15
  Observe 1         22         55
  Accuracy          :  84.58 %
  Sensibilite       :  71.43 %
  Specificite       :  90.80 %
  Val. pred. pos.   :  78.57 %
  Val. pred. neg.   :  87.06 %
```

Sur l'échantillon d'apprentissage, le modèle final présente de très bonnes performances avec une accuracy de 84,58%. Il classe correctement la majorité des observations, avec une spécificité élevée (90,80%) indiquant une très bonne détection des survivants, et une sensibilité satisfaisante (71,43%) pour les décès. Les valeurs prédictives montrent également une bonne fiabilité globale du modèle sur les données d'entraînement, ce qui traduit un bon ajustement.

4.6.2 Sur l'échantillon de validation (TEST)

```
--- Matrice de confusion : TEST  - Modele final (seuil = 0.5 )---
                Predit 0   Predit 1
  Observe 0         35          5
  Observe 1          9         10
  Accuracy          :  76.27 %
  Sensibilite       :  52.63 %
  Specificite       :  87.50 %
  Val. pred. pos.   :  66.67 %
  Val. pred. neg.   :  79.55 %
```

Sur l'échantillon de validation, les performances du modèle diminuent légèrement, avec une accuracy de 76,27%. La spécificité reste élevée (87,50%), ce qui signifie que les survivants sont toujours bien identifiés, mais la sensibilité chute à 52,63%, indiquant que près de la moitié des décès ne sont pas détectés.

Modèle complet : Résultats identiques au modèle final sur le test : Accuracy = 76,27%, Sensibilité = 52,63%, Spécificité = 87,50%.

4.7 Comparaison des modèles : Courbes ROC

La figure 4.13 superpose les courbes ROC des trois configurations évaluées. La figure 4.14 récapitule les AUC obtenues.

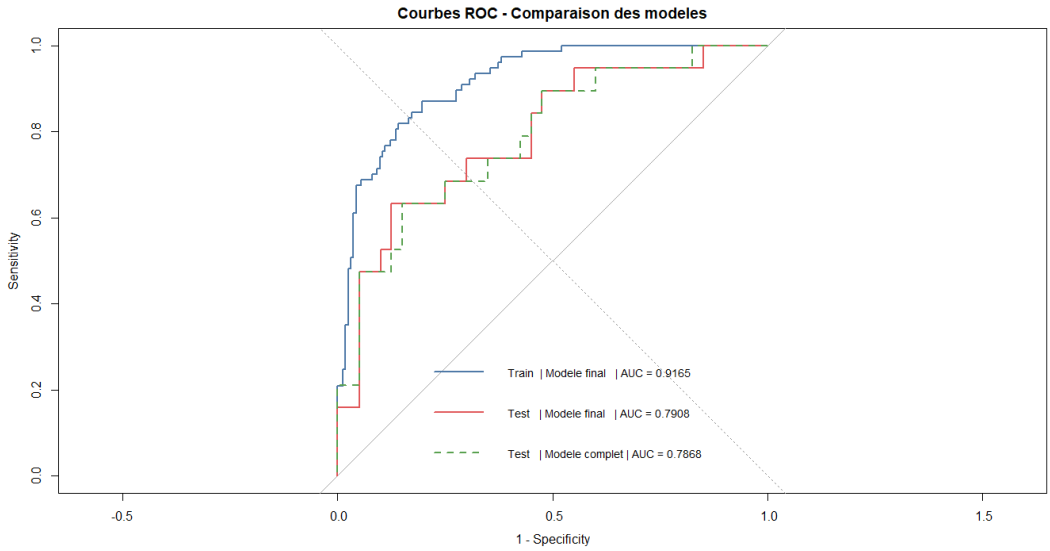

FIGURE 4.13 – Courbes ROC – Comparaison des modèles sur TRAIN et TEST

```
=== AUC DES MODELES ===
> cat(sprintf("%-40s : %.4f\n", "Train  - Modele final",   auc_train))
Train  - Modele final                    : 0.9165
> cat(sprintf("%-40s : %.4f\n", "Test   - Modele final",   auc_test_f))
Test   - Modele final                    : 0.7908
> cat(sprintf("%-40s : %.4f\n", "Test   - Modele complet", auc_test_c))
Test   - Modele complet                  : 0.7868
```

FIGURE 4.14 – Valeurs d'AUC par modèle et par échantillon

Les courbes ROC montrent que le modèle final possède un excellent pouvoir discriminant sur l'échantillon d'apprentissage, avec une AUC de 0,9165, indiquant une très bonne capacité à distinguer les patients décédés des survivants. Sur l'échantillon de validation, l'AUC diminue à 0,7908, ce qui reste acceptable et reflète une légère perte de performance, classique en présence de nouvelles données.

De plus, les performances du modèle final et du modèle complet sur le test sont très proches (AUC de 0,7908 contre 0,7868), ce qui confirme que le modèle final, bien que plus simple, conserve une capacité de discrimination équivalente. Cela renforce l'intérêt de privilégier le modèle parcimonieux, qui offre un bon compromis entre performance et interprétabilité.

Le **test de DeLong** comparant les AUC des deux modèles sur le test donne $Z = 0{,}543$, $p = 0{,}587$: **pas de différence significative** ($p > 0{,}05$) entre leurs performances discriminantes.

CHAPITRE 5

DISCUSSION ET INTERPRÉTATION

5.1 Interprétation clinique des Odds Ratios

— **Âge (OR = 1,043 ; IC : [1,008 – 1,080])**
Chaque année supplémentaire multiplie le risque de décès par 1,043 (+4,3%). L'âge avancé est associé à des comorbidités plus nombreuses, une moindre capacité de récupération et une réponse physiologique moins efficace aux traitements.

— **Fraction d'éjection (OR = 0,913 ; IC : [0,878 – 0,950])**
Chaque point de pourcentage supplémentaire réduit le risque de décès de 8,7%. La fraction d'éjection est l'**indicateur cardiaque fondamental** : un cœur qui pompe efficacement réduit considérablement la mortalité par insuffisance cardiaque.

— **Créatinine sérique (OR = 2,215 ; IC : [1,507 – 3,255])**
C'est le **facteur de risque le plus puissant** du modèle. Chaque unité supplémentaire (mg/dL) multiplie le risque de décès par 2,2. Ce marqueur reflète la fonction rénale : un taux élevé traduit une insuffisance rénale (syndrome cardio-rénal), complication létale fréquente de l'insuffisance cardiaque avancée.

— **Sodium sérique (OR = 0,901 ; IC : [0,822 – 0,989])**
Chaque mEq/L supplémentaire réduit le risque de décès de 9,9%. L'hyponatrémie (faible sodium) est un marqueur pronostique défavorable reconnu : elle reflète une rétention hydrique excessive et une activation du système rénine-angiotensine-aldostérone.

— **Durée de suivi (OR = 0,977 ; IC : [0,970 – 0,984])**
Chaque jour supplémentaire réduit le risque de décès de 2,3%. Cette variable capture l'effet bénéfique d'une prise en charge médicale prolongée et régulière, avec ajustements thérapeutiques.

5.2 Qualité globale du modèle

Synthèse des indicateurs de qualité

- **McFadden = 0,464** ($> 0{,}4$: excellent)
- **Nagelkerke = 0,617** (61,7% de variabilité expliquée)
- **AUC train = 0,917** (excellent pouvoir discriminant)
- **AUC test = 0,791** (acceptable, $> 0{,}7$)
- **Hosmer-Lemeshow** $p = 0{,}638 > 0{,}05$ (bonne calibration)
- **VIF** < 2 pour toutes les variables (absence de multicolinéarité)
- **Accuracy test = 76,27%** avec spécificité = 87,50%

5.3 Comparaison finale des modèles

Le **modèle final parcimonieux** est préférable au modèle complet pour les raisons suivantes :

1. AIC réduit de 187,06 à **173,53** ($-13{,}5$ points).
2. BIC réduit de 232,31 à **194,41** ($-37{,}9$ points).
3. 5 variables au lieu de 12 : **interprétabilité clinique**.
4. AUC test légèrement supérieure : 0,7908 vs 0,7868.
5. Mêmes performances sur le test, validant la non-perte d'information (LRT complet vs final : $p = 0{,}9996$).

5.4 Limites

- **Taille réduite de l'échantillon test** (59 observations) : les estimations de performance peuvent être instables.
- **Sensibilité modérée sur le test** (52,63%) : la moitié des décès réels ne sont pas détectés au seuil 0,5. Un abaissement du seuil améliorerait la sensibilité au détriment de la spécificité.
- **Surapprentissage modéré** : AUC train (0,917) $\gg$ AUC test (0,791), inhérent à la faible taille de l'échantillon.
- **Données mono-centre** : collectées dans un seul hôpital pakistanais, limitant la généralisation.

CONCLUSION ET RECOMMANDATIONS

Ce travail avait pour objectif d'appliquer la démarche complète de modélisation par régression logistique à un jeu de données cliniques réelles portant sur des patients atteints d'insuffisance cardiaque. L'ensemble des étapes méthodologiques, allant de l'analyse exploratoire des données jusqu'à la validation du modèle, a permis de construire un modèle final à la fois performant et interprétable sur le plan clinique. Ce modèle repose sur cinq variables clés : l'âge, la fraction d'éjection, la créatinine sérique, le sodium sérique et la durée de suivi.

Les résultats obtenus mettent en évidence de très bonnes performances statistiques, avec un pouvoir discriminant élevé et une bonne qualité d'ajustement. Ils confirment notamment le rôle déterminant de la fonction rénale et de la fonction cardiaque dans la prédiction du risque de décès, en cohérence avec la littérature médicale. Le modèle obtenu constitue ainsi un outil pertinent d'aide à la décision, permettant d'identifier les patients les plus à risque.

Cependant, certaines limites doivent être prises en compte. La taille relativement réduite de l'échantillon de validation peut affecter la stabilité des performances estimées, et la sensibilité du modèle reste modérée au seuil de décision standard. De plus, les données étant issues d'un seul centre hospitalier, la généralisation des résultats à d'autres populations demeure limitée.

Dans cette perspective, plusieurs pistes d'amélioration peuvent être envisagées. L'ajustement du seuil de classification à une valeur inférieure à 0,5 permettrait d'améliorer la sensibilité du modèle, ce qui est particulièrement important en contexte médical afin de réduire le risque de non-détection des patients à haut risque. L'augmentation de la taille de l'échantillon, notamment à travers des données multi-centriques, renforcerait la robustesse et la validité externe du modèle. Par ailleurs, l'exploration d'autres approches statistiques, telles que les modèles de survie ou d'autres extensions des modèles linéaires généralisés, pourrait enrichir l'analyse. Enfin, la prise en compte du déséquilibre des classes, par des techniques comme SMOTE, permettrait d'améliorer la détection de la classe minoritaire correspondant aux décès.

Ainsi, ce travail illustre l'intérêt des méthodes statistiques dans l'analyse de données médicales et souligne leur rôle essentiel dans l'amélioration de la prise en charge des patients et la prévention des risques.

BIBLIOGRAPHIE

[1] Chicco, D. et Jurman, G. (2020). *Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone*. BMC Medical Informatics and Decision Making, 20(16). https://doi.org/10.1186/s12911-020-1023-5

[2] Larxel (2020). *Heart Failure Prediction Dataset*. Kaggle. https://www.kaggle.com/datasets/andrewmvd/heart-failure-clinical-data

[3] McCullagh, P. et Nelder, J.A. (1989). *Generalized Linear Models* (2e éd.). Chapman & Hall/CRC.

[4] Hosmer, D.W., Lemeshow, S. et Sturdivant, R.X. (2013). *Applied Logistic Regression* (3e éd.). Wiley.

ANNEXE A

CODE R COMPLET

```r

#   TP : REGRESSION LOGISTIQUE SOUS R
#   Prediction du Deces par Insuffisance Cardiaque
#   Dataset : Heart Failure Clinical Records (Kaggle, 299 obs.)
#   Variable reponse : DEATH_EVENT (1 = Decede, 0 = Survivant)
# ================================================================
# ----------------------------------------------------------------
# ETAPE 0 : PACKAGES
# ----------------------------------------------------------------

install.packages(c("ggplot2", "dplyr", "MASS", "car",
                   "pROC", "lmtest", "corrplot", "caret"))

library(ggplot2); library(dplyr) ; library(MASS) ; library(car)
   library(pROC) ; library(lmtest) ; library(corrplot) ; library(caret
   )

# ----------------------------------------------------------------
# ETAPE 1 : CHARGEMENT ET PREPARATION DES DONNEES
# ----------------------------------------------------------------

df <- read.csv("heart_failure_clinical_records_dataset.csv")

str(df)
cat("Observations :", nrow(df), "\n")
cat("Variables    :", ncol(df), "\n")

print(colSums(is.na(df)))
cat("Nombre de lignes dupliquees :", sum(duplicated(df)), "\n")

print(summary(df))

tab_rep <- table(df$DEATH_EVENT)
print(tab_rep)
print(round(prop.table(tab_rep) * 100, 1))
```

```r

df$anaemia             <- as.factor(df$anaemia)
df$diabetes            <- as.factor(df$diabetes)
df$high_blood_pressure <- as.factor(df$high_blood_pressure)
df$sex                 <- as.factor(df$sex)
df$smoking             <- as.factor(df$smoking)
df$DEATH_EVENT         <- as.factor(df$DEATH_EVENT)

# ----------------------------------------------------------------
# ETAPE 2 : ANALYSE EXPLORATOIRE
# ----------------------------------------------------------------

vars_cont <- c("age", "creatinine_phosphokinase", "ejection_fraction",
               "platelets", "serum_creatinine", "serum_sodium", "time"
                  )

# --- Boxplots ---
par(mfrow = c(2, 4), mar = c(5, 4, 3, 1))
for (v in vars_cont) {
  boxplot(as.numeric(df[[v]]) ~ df$DEATH_EVENT,
          main   = v,
          names  = c("Survie", "Deces"),
          col    = c("#4E79A7", "#E15759"),
          border = "gray40",
          ylab   = "")
}
par(mfrow = c(1, 1))

# --- Matrice de correlation ---
df_num <- df
df_num[vars_cont] <- lapply(df_num[vars_cont], as.numeric)
corrplot(cor(df_num[, vars_cont]),
         method      = "color",
         type        = "upper",
         tl.cex      = 0.8,
         col         = colorRampPalette(c("#E15759", "white", "#4E79A7
            "))(200),
         addCoef.col = "black",
         number.cex  = 0.7,
         tl.col      = "black",
         title       = "Matrice de Correlation",
         mar         = c(0, 0, 2, 0))

# ----------------------------------------------------------------
# ETAPE 3 : SPLIT 80/20 STRATIFIE
# ----------------------------------------------------------------

```

```r
set.seed(42)

index_train <- createDataPartition(
  y     = df$DEATH_EVENT,
  p     = 0.80,
  list  = FALSE
)
train <- df[ index_train, ]
test  <- df[-index_train, ]

cat("Train :", nrow(train), "observations\n")
cat("Test  :", nrow(test),  "observations\n")

print(round(prop.table(table(train$DEATH_EVENT)) * 100, 1))
print(round(prop.table(table(test$DEATH_EVENT))  * 100, 1))

train$DEATH_EVENT_num <- as.numeric(train$DEATH_EVENT) - 1
test$DEATH_EVENT_num  <- as.numeric(test$DEATH_EVENT)  - 1
# ----------------------------------------------------------------
# ETAPE 4 : MODELES LOGISTIQUES
# ----------------------------------------------------------------

# --- Modele nul ---
model_nul <- glm(DEATH_EVENT_num ~ 1,
                 family = binomial(link = "logit"),
                 data   = train)

# --- Modele complet ---
model_complet <- glm(
  DEATH_EVENT_num ~ age + anaemia + creatinine_phosphokinase +
    diabetes + ejection_fraction + high_blood_pressure +
    platelets + serum_creatinine + serum_sodium + sex + smoking + time
      ,
  family = binomial(link = "logit"),
  data   = train
)
print(summary(model_complet))

cat("Deviance nulle     :", round(model_complet$null.deviance, 3), "\n
    ")
cat("Deviance residuelle:", round(deviance(model_complet), 3), "\n")
cat("AIC                :", round(AIC(model_complet), 2), "\n")
cat("BIC                :", round(BIC(model_complet), 2), "\n")

# --- Odds Ratios modele complet ---
OR_complet <- exp(cbind(OR     = coef(model_complet),
                        IC_inf = confint.default(model_complet)[, 1],
```

```
                          IC_sup = confint.default(model_complet)[, 2]))
print(round(OR_complet, 4))

# --- Modele final (Stepwise AIC) ---
model_final <- stepAIC(model_complet, direction = "both", trace =
    FALSE)

print(summary(model_final))
cat("Variables retenues :", paste(names(coef(model_final))[-1],
    collapse = ", "), "\n")
cat("AIC modele final   :", round(AIC(model_final), 2), "\n")
cat("BIC modele final   :", round(BIC(model_final), 2), "\n")

# --- Odds Ratios modele final ---
OR_final <- exp(cbind(OR    = coef(model_final),
                      IC_inf = confint.default(model_final)[, 1],
                      IC_sup = confint.default(model_final)[, 2]))
print(round(OR_final, 4))

# ----------------------------------------------------------------
# ETAPE 5 : TESTS D'HYPOTHESES
# ----------------------------------------------------------------
# --- Test LRT : modele final vs modele nul ---
print(lrtest(model_nul, model_final))

# --- Test LRT : modele complet vs modele final ---
print(lrtest(model_final, model_complet))

# --- Test de Wald ---
print(round(coef(summary(model_final)), 4))

# --- Pseudo R2 ---
L0 <- as.numeric(logLik(model_nul))
LM <- as.numeric(logLik(model_final))
n  <- nrow(train)

r2_mcf <- 1 - LM / L0
r2_cox <- 1 - exp((2 / n) * (L0 - LM))
r2_nag <- r2_cox / (1 - exp(2 * L0 / n))

cat("McFadden  :", round(r2_mcf, 4), "\n")
cat("Cox-Snell :", round(r2_cox, 4), "\n")
cat("Nagelkerke:", round(r2_nag, 4), "\n")

# ----------------------------------------------------------------
# ETAPE 6 : ADEQUATION DU MODELE
# ----------------------------------------------------------------
```

```r
# --- Test par la deviance ---
dev_res <- deviance(model_final)
ddl     <- df.residual(model_final)
p_dev   <- 1 - pchisq(dev_res, ddl)

cat("Deviance residuelle :", round(dev_res, 4), "\n")
cat("Degres de liberte   :", ddl, "\n")
cat("p-value (chi2)      :", round(p_dev, 4), "\n")
if (p_dev > 0.05) cat("=> Bonne adequation du modele (p > 0.05)\n") else
  cat("=> Manque d adequation (p < 0.05)\n")

# --- Test de Hosmer-Lemeshow ---
hoslem_test <- function(y, yhat, g = 10) {
  coupe    <- quantile(yhat, probs = seq(0, 1, length = g + 1))
  coupe[1] <- coupe[1] - 0.001
  grp  <- cut(yhat, breaks = coupe, labels = FALSE)
  Obs1 <- tapply(y,    grp, sum)
  Exp1 <- tapply(yhat, grp, sum)
  n_g  <- tapply(y,    grp, length)
  Obs0 <- n_g - Obs1
  Exp0 <- n_g - Exp1
  X2   <- sum((Obs1 - Exp1)^2 / Exp1) + sum((Obs0 - Exp0)^2 / Exp0)
  p    <- 1 - pchisq(X2, df = g - 2)
  cat("=== TEST DE HOSMER-LEMESHOW ===\n")
  cat("Statistique X2    :", round(X2, 4), "\n")
  cat("Degres de liberte :", g - 2, "\n")
  cat("p-value           :", round(p, 4), "\n")
  if (p > 0.05) cat("=> Bonne adequation (p > 0.05)\n") else
    cat("=> Manque d adequation (p < 0.05)\n")
  invisible(list(X2 = X2, df = g - 2, p = p))
}

pred_train <- predict(model_final, type = "response")
hoslem_test(train$DEATH_EVENT_num, pred_train)


# ----------------------------------------------------------------
# ETAPE 7 : ANALYSE DES RESIDUS
# ----------------------------------------------------------------
# --- Graphiques diagnostiques standard ---
par(mfrow = c(2, 2))
plot(model_final,
     pch        = 20,
     col        = adjustcolor("#4E79A7", 0.6),
     sub.caption = "Diagnostics - Modele logistique final")
par(mfrow = c(1, 1))
```

```r

# --- Residus de deviance ---
res_dev <- residuals(model_final, type = "deviance")
print(round(summary(res_dev), 4))

# Figure sans annotation
plot(fitted(model_final), res_dev,
     pch  = 20,
     col  = adjustcolor("#4E79A7", 0.5),
     xlab = "Probabilites ajustees",
     ylab = "Residus de deviance",
     main = "Residus de deviance vs probabilites ajustees (TRAIN)")
abline(h   = c(-2, 0, 2),
       col = c("red", "gray40", "red"),
       lty = c(2, 1, 2))

# Figure avec identification des points aberrants
idx_aberrants <- which(abs(res_dev) > 2)
text(fitted(model_final)[idx_aberrants],
     res_dev[idx_aberrants],
     labels = idx_aberrants,
     pos = 3, cex = 0.7, col = "red")
cat("Observations avec |residus| > 2 :", idx_aberrants, "\n")

# --- Residus de Pearson ---
res_pear <- residuals(model_final, type = "pearson")
print(round(summary(res_pear), 4))

# --- Distance de Cook ---
cook       <- cooks.distance(model_final)
seuil_cook <- 4 / nrow(train)
pts_cook   <- which(cook > seuil_cook)

cat("Points influents (Cook > 4/n =", round(seuil_cook, 4), ") :",
    length(pts_cook), "\n")
cat("Indices :", pts_cook, "\n")

plot(cook,
     type = "h",
     col  = ifelse(cook > seuil_cook, "#E15759", "#4E79A7"),
     main = "Distance de Cook - Echantillon TRAIN",
     ylab = "Distance de Cook",
     xlab = "Observation")
abline(h = seuil_cook, col = "red", lty = 2)

# --- Leviers ---
lev       <- hatvalues(model_final)
```

```r
p_coef    <- length(coef(model_final))
seuil_lev <- 2 * p_coef / nrow(train)
pts_lev   <- which(lev > seuil_lev)
cat("Points a levier eleve (seuil = 2p/n =", round(seuil_lev, 4), ") : ", length(pts_lev), "\n")

# --- VIF ---
print(round(vif(model_final), 3))
cat("=> VIF < 5 : pas de multicollinearite\n")

# ----------------------------------------------------------------
# ETAPE 8 : MATRICES DE CONFUSION
# ----------------------------------------------------------------

prob_test         <- predict(model_final,   newdata = test, type = "response")
prob_test_complet <- predict(model_complet, newdata = test, type = "response")

afficher_mat_conf <- function(y_obs, prob, seuil = 0.5, nom = "") {
  pred_cl      <- ifelse(prob >= seuil, 1, 0)
  mat          <- table(Observe = y_obs, Predit = pred_cl)
  mat_complete <- matrix(0, nrow = 2, ncol = 2,
                         dimnames = list(c("0","1"), c("0","1")))
  for (i in rownames(mat))
    for (j in colnames(mat))
      mat_complete[i, j] <- mat[i, j]

  VN  <- mat_complete["0","0"]
  FP  <- mat_complete["0","1"]
  FN  <- mat_complete["1","0"]
  VP  <- mat_complete["1","1"]
  acc <- round((VP + VN) / sum(mat_complete) * 100, 2)
  sens <- round(ifelse((VP + FN) > 0, VP / (VP + FN), NA) * 100, 2)
  spec <- round(ifelse((VN + FP) > 0, VN / (VN + FP), NA) * 100, 2)
  vpp  <- round(ifelse((VP + FP) > 0, VP / (VP + FP), NA) * 100, 2)
  vpn  <- round(ifelse((VN + FN) > 0, VN / (VN + FN), NA) * 100, 2)

  cat("\n--- Matrice de confusion :", nom, "(seuil =", seuil, ")---\n")
  cat(sprintf("                 Predit 0   Predit 1\n"))
  cat(sprintf("  Observe 0  %9d  %9d\n", VN, FP))
  cat(sprintf("  Observe 1  %9d  %9d\n", FN, VP))
  cat(sprintf("  Accuracy          : %6.2f %%\n", acc))
  cat(sprintf("  Sensibilite       : %6.2f %%\n", sens))
  cat(sprintf("  Specificite       : %6.2f %%\n", spec))
  cat(sprintf("  Val. pred. pos.   : %6.2f %%\n", vpp))
```

```
  cat(sprintf("  Val. pred. neg.   : %6.2f %%\n", vpn))

  invisible(list(mat = mat_complete, acc = acc, sens = sens,
                 spec = spec, vpp = vpp, vpn = vpn))
}

r_train  <- afficher_mat_conf(train$DEATH_EVENT_num, pred_train,
                              seuil = 0.5, nom = "TRAIN - Modele final")
r_test_f <- afficher_mat_conf(test$DEATH_EVENT_num,  prob_test,
                              seuil = 0.5, nom = "TEST  - Modele final")
r_test_c <- afficher_mat_conf(test$DEATH_EVENT_num,  prob_test_complet,
                              seuil = 0.5, nom = "TEST  - Modele complet")

# ---------------------------------------------------------------
# ETAPE 9 : COURBES ROC ET COMPARAISON
# ---------------------------------------------------------------

roc_train  <- roc(train$DEATH_EVENT_num, pred_train,         quiet = TRUE)
roc_test_f <- roc(test$DEATH_EVENT_num,  prob_test,          quiet = TRUE)
roc_test_c <- roc(test$DEATH_EVENT_num,  prob_test_complet,  quiet = TRUE)

auc_train  <- round(auc(roc_train),  4)
auc_test_f <- round(auc(roc_test_f), 4)
auc_test_c <- round(auc(roc_test_c), 4)

cat(sprintf("%-40s : %.4f\n", "Train  - Modele final",   auc_train))
cat(sprintf("%-40s : %.4f\n", "Test   - Modele final",   auc_test_f))
cat(sprintf("%-40s : %.4f\n", "Test   - Modele complet", auc_test_c))

plot(roc_train,
     col         = "#4E79A7",
     lwd         = 2.5,
     legacy.axes = TRUE,
     main        = "Courbes ROC - Comparaison des modeles")
lines(roc_test_f, col = "#E15759", lwd = 2.5)
lines(roc_test_c, col = "#59A14F", lwd = 2,  lty = 2)
abline(a = 0, b = 1, col = "gray60", lty = 3, lwd = 1.5)
legend("bottomright",
       legend = c(
         paste("Train  | Modele final   | AUC =", auc_train),
```

```
          paste("Test   | Modele final   | AUC =", auc_test_f),
          paste("Test   | Modele complet | AUC =", auc_test_c)
        ),
        col = c("#4E79A7", "#E15759", "#59A14F"),
        lwd = c(2.5, 2.5, 2),
        lty = c(1, 1, 2),
        bty = "n",
        cex = 0.9)

# --- Test de DeLong ---
print(roc.test(roc_test_f, roc_test_c))
```

Listing A.1 – Code R complet – TP Régression Logistique